

Часть I. Модели и нагрузки

- 1. Знакомство с AI Infra
- 2. Архитектура моделей
- 3. Нагрузки инференса и обучения



Часть II. Чипы и системы

- 4. Архитектура ускорителей
- 5. Операторы и среда выполнения
- 6. Суперузлы
- 7. Сети ЦОД



Часть III. Системы инференса и обучения

- 8. Оптимизация инференса
- 9. Распределённый инференс
- 10. Системы обучения
- 11. Планирование ресурсов и среда выполнения
- 12. Взаимодействие устройств, периферии и облака