



MHA: отдельная группа KV для каждого запроса



GQA: одна группа KV на два запроса



MQA: одна группа KV на четыре запроса

