



Путь 1: сначала развернуть каждый токен контекста



Сначала для контекста вычисляется $K = s U_k$

Путь 2: сначала преобразовать текущий запрос



Сначала для запроса вычисляется $q U_k^T$