

Токены промпта → 20 слоёв энкодера



Представление
последнего слоя энкодера
Проекция в глобальные KV



Последние ≤ 128 токенов
промпта
Взять выход энкодера



Прогон через 20 слоёв
декодера
Построить локальное SWA



Декодер читает глобальные KV



Новый токен: энкодер → декодер → выход