


Путь решения: один прямой проход, 8 ответов одновременно через 70.5 ms

prefill



prefill: 1929 токенов, ограничение — вычисления


Считывание
распределений



Распределения для 8 позиций считываются за раз


Путь LLM: после того же prefill последовательно генерируются 64 токена

prefill



63 шага decode по 9.2 ms, ограничение — пропускная
способность; последовательно

Генерация по
токенам



0

71

200

400

651

Время от начала запроса (ms)