

Обработка входа 8K с нуля

Обычные полные слои: 8,192 токена × 40 слоёв

Энкодер CED
8,192 токена × 20 слоёв

Локальный
повтор
128 × 20

327,680 → 166,400 токен-слоёв

Отдельно: глобальная KV-проекция, внимание и прочее

При генерации выполняются все 40 слоёв основной сети