

Изображение кодируется в визуальные токены и подаётся
в языковую модель

Изображение 640×640 пикселей



Блоки 16×16 пикселей $\rightarrow$ сетка 40×40



Слияние соседних блоков $2 \times 2 \rightarrow 20 \times 20$ токенов