

400 визуальных токенов, каждый — вектор признаков

Четыре группы визуальных признаков шириной 2560

```
graph TD; A[400 визуальных токенов, каждый — вектор признаков] --> B[Четыре группы визуальных признаков шириной 2560]; B --> C[Результат кодирования: 400 x 4 x 2560 x 2 байта]; C --> D[В языковой сети дополнительно создаётся KV-кэш каждого слоя];
```

Результат кодирования: $400 \times 4 \times 2560 \times 2$ байта

В языковой сети дополнительно создаётся KV-кэш каждого
слоя