

Уровень вложенности задаёт срок хранения

Обход выходных блоков i_o , j_o

Создать FP32-аккумулятор: 16 KiB



Цикл k_o : 128 раз

Читать блоки A , W → обновить аккумулятор



Конец редукции → округление BF16 → SiLU