

В каждой строке своя группа экспертов, KV
дублируется по столбцам

Группа 0

GPU 0
KV-головы 0, 1

GPU 1
KV-головы 2, 3

Группа 1

GPU 2
KV-головы 0, 1

GPU 3
KV-головы 2, 3

Группа 2

GPU 4
KV-головы 0, 1

GPU 5
KV-головы 2, 3

Группа 3

GPU 6
KV-головы 0, 1

GPU 7
KV-головы 2, 3

Размерность экспертов строки: слева 768, справа 768