

Внимание и маршрутизатор: каждый GPU обрабатывает свои токены



All-to-All dispatch: входы идут на GPU выбранных экспертов



GPU 0

E0

E1

E2

E3



GPU 1

E4

E5

E6

E7



Возврат All-to-All: результаты идут на исходные GPU токенов и объединяются по весам маршрута