

Начало передачи: полный объём
занят с обеих сторон

Qwen3-8B, GQA



DeepSeek-V3, компактный
MLA



Копирование данных; ширина блоков пропорциональна числу
байтов