

Иерархия KV-хранилищ для одной A100

HBM
 ≤ 63.6 GB

Уже на GPU
Загрузка: 0 ms

Память хоста
256 GiB

PCIe 4.0 x16, 25 GB/s
Загрузка: 48.3 ms

Локальный SSD
3.84 TB

Последовательное чтение
SSD: 7.1 GB/s
Загрузка: 170 ms

Удалённый пул хранилища
Растёт с числом узлов

Сетевая карта: 25 GB/s,
затем PCIe
Загрузка: 96.6 ms

Для сравнения: пересчёт этого префикса
8K на A100 ≈ 856 ms