

PD: разделение обработки входа
и генерации

Передача KV-кэша контекста

